Instituto Tecnológico y de Estudios Superiores de Monterrey
Campus Sonora Norte

Reporte de Segundo Avance

Estancia Profesional Modelo Dual
Ford Motor Company
Proyecto HERBIEE

Pablo Ernesto Moreno Cruz | A01255437
Jorge Antonio Flores Hernandez | A01254623

Tutor:
Mario Alberto Duran Vega

30 de Octubre de 2026
Hermosillo, Sonora, Mexico

Índice

Objetivos de la Etapa…….. 3

Trabajo Realizado……... 4

Cooperación en el Equipo……... 5

Cooperación con los Tutores…… 5

Nuevo Plan de trabajo…… 6

Conclusiones…….. 11

Bibliografía…….. 12

Anexos…….. 12

Objetivos de la Etapa

- Esta etapa incluye terminar la Fase 1, que se llama Memoria, y comenzar la Fase 2, que se llama Conectores y UI.

- Memoria a nivel usuario lista para producción. La conversación debe sobrevivir despliegues y debe crecer a varias instancias, como Memorystore y Redis. Además, los embeddings migran a FordLLM y se permite la extracción automática de aprendizajes por turno.

- Memoria a nivel planta. Se quiere crear un repositorio de conocimiento compartido, cuidado por Process Coaches, que solo se añada al contexto del agente. También el repositorio debe conocer líneas, turnos y tripulaciones.

- Prototipo con dashboard de KPIs y memoria funcional, que es el resultado esperado de la Fase 1.

- Arrancar el sistema modular de conectores MCP, para que añadir una fuente nueva sea solo un cambio de configuración y no de código.

- Avanzar el diseño final de la UI con lo aprendido de la sombra a los Process Coaches.

- Medir la calidad del agente con un arnés de evaluación automatizado.

Trabajo Realizado

2.1 Objetivos alcanzados

- **Memoria persistente entre sesiones:** El agente guarda su memoria en Memorystore (Redis). Las conversaciones ya no se pierden cuando se despliega o cuando se escalan a varias instancias. El usuario también puede volver a chats anteriores desde un historial, con sus gráficas y reportes guardados.
- **Memoria a nivel usuario:** El agente guarda su memoria en la base de datos de embeddings FordLLM. Se activa la extracción automática de aprendizajes en cada turno de conversación. Para que el supervisor controle el proceso, el agente pide permiso antes de guardar algo y, en el panel “Mis memorias”, el supervisor puede ver y borrar lo que el asistente recuerda de él.
- **Memoria a nivel planta:** Se creó un repositorio de conocimiento compartido con un flujo de curación para que el conocimiento sea confiable: cualquier empleado puede proponer contenido, el Process Coach aprueba, edita o rechaza cada propuesta, y el conocimiento aprobado se agrega solo al contexto del agente junto con la memoria personal. Además, el agente conoce la operación de la planta (líneas, turnos y rotación de tripulaciones) y se definieron roles de acceso (Admin, Supervisor y Process Coach).
- **Dashboard de KPIs:** Muestra los indicadores de calidad y productividad (FRC, JPH, PFC) en vivo desde BigQuery, con detalle por estación y sugerencias de estaciones para evaluación PJO. Permite a cada supervisor crear widgets describiendo en lenguaje natural la gráfica que necesita, organizar su propia vista del dashboard y exportar los reportes generados.
- **Sistema modular y escalable para MCPs (adelantado de la Fase 2):** Los conectores ahora se registran en una base de datos y los administra un gateway común con autenticación por conector y protección ante fallas. Agregar una nueva fuente de datos es cuestión de configuración, no de recompilar el agente. Sobre esta base se integró el conector oficial de Microsoft 365 de Ford (correo, calendario y Teams), y el conector de Outlook se mantiene como respaldo.
- **Calidad y estándares:** Se construyó un arnés de evaluación automática del agente (obteniendo entre 92 % y 97 % de respuestas correctas), la API se alineó al estándar de diseño de APIs de Ford, se cerraron los hallazgos de seguridad del análisis estático y se redactó la documentación para mantenedores.

2.2 Actividades pendientes

- **Diseño final de UI:** Ya se aplicó un rediseño general (temas claro/oscuro, español/inglés, nuevos componentes); queda pendiente el pulido final con base en la retroalimentación de los usuarios.
- **Sesiones de feedback:** Falta realizar la sesión formal con Process Coaches usando la plataforma en un entorno controlado.
- **Implementación de más conectores:** Falta habilitar y validar de punta a punta el conector de Microsoft 365 en el ambiente de desarrollo, así como integrar fuentes de datos de planta adicionales a través del gateway.
- **Contenido oficial de memoria de planta:** La plataforma está lista, pero falta cargar los procedimientos oficiales (SOPs y matriz de escalación Andon).

- **Limpieza de código:** Retirar componentes y scripts obsoletos una vez que se estabilice el sistema.
- **MVP de HERBIEE:** El entregable final y funcional.

2.3 Razones por las que no se cumplieron completamente las actividades del primer avance

- **Sesiones de feedback:** Se decidió esperar a que la plataforma tuviera estables la memoria, los KPIs en vivo y los conectores para que la retroalimentación fuera sobre la experiencia real y no sobre funciones incompletas.
- **Diseño final de UI:** Depende directamente de las sesiones de feedback y se priorizó adelantar el sistema de conectores MCP por representar mayor riesgo técnico.
- **Contenido de memoria de planta:** Requiere que el área de negocio entregue y valide los documentos oficiales, siendo una dependencia externa al equipo de desarrollo.
- **Conector de Microsoft 365:** Su activación se retrasó por dependencias de infraestructura de Ford (certificados raíz privados, registro del cliente OAuth y accesos al servicio) que fue necesario resolver antes de probar en el ambiente de desarrollo.

Factores externos generales: Tiempos de respuesta en solicitudes de permisos (FIM), demoras en el pipeline de despliegue y cambios en la disponibilidad de modelos de FordLLM que obligaron a adaptar el cliente del agente.

Cooperación en el equipo

Durante la elaboración del proyecto no se han presentado problemas dentro del equipo ni problemas por parte de los empleados de la empresa con los que trabajamos.
Para trabajar en el proyecto estamos utilizando este flujo de trabajo en github:

- Cada cambio entra en su propia rama y llega a dev por medio de un Pull Request.
- Siempre se trabajan partes distintas del código simultáneamente para evitar conflictos

Tenemos juntas internas regularmente para resolver problemas y determinar el mejor plan de acción para llevar a cabo una tarea.

Cooperación con los tutores

Cada semana los viernes a la 1:00PM tenemos sesiones con nuestros supervisores directos donde les mostramos el proyecto HERBIEE y los avances que se lleven, esto con la finalidad de recibir retroalimentación de parte de ellos para realizar correcciones o cambios que sean necesarios en base a las observaciones que se realicen, además nos ayudan dándonos su perspectiva al momento de tomar decisiones relacionadas con el proyecto y qué cosas necesitamos tomar en cuenta para llevarlas a cabo.

A lo largo de la elaboración nos han asistido con varios accesos, entre ellos se encuentran bases de datos donde se ubica la información de las líneas que se necesita para poder trabajar con los datos y así lograr que el agente sea capaz de analizar esa información y realizar gráficas, reportes, tablas, etc.

Además de los accesos ya mencionados también nos han ayudado a comprender cómo funciona la burocracia dentro de ford al momento de trabajar en un proyecto de esta índole.

- Donde descargar las plataformas para trabajar
- Que cosas se pueden descargar
- Cómo solicitar permisos
- Cómo trabajar con las plataformas de la empresa
- Entre muchas otras cosas más.

Nuevo plan de trabajo

- 5.1Actividades programadas que se cumplieron a tiempo
- Introducción
- Análisis de la arquitectura actual (24 – 26 ago).
- Investigación del stack de tecnologías (27 – 28 ago).
- Planeación de la arquitectura final (31 ago – 2 sep).
- Prototipo de UI (3 – 4 sep).
- Fase 1 — Memoria
- Sombra en piso con los Process Coaches (17 – 18 sep).
- Memoria persistente entre sesiones.
- Memoria a nivel usuario.
- Memoria a nivel planta.
- Fase 2 — Conectores y UI (adelantadas)
- Sistema modular y escalable para MCPs. Estaba planeado hasta el 13 de noviembre y quedó listo el 22 de octubre.
- Integración del conector de Microsoft 365. Es el primero de los conectores adicionales.
- 5.2 Actividades pendientes

Fase 2 — Conectores y UI (2 – 13 de noviembre)

- 2 – 4 nov · JFH: activar el conector de Microsoft 365 en dev y validarlo de punta a punta (conexión, correo y calendario).
- 2 – 6 nov · JFH:
- Conector de datos de planta (QLS/FIS) a través del gateway.
- Validación en vivo del calendario de tripulaciones.
- 2 – 6 nov · PMC: pulido final de la UI: vistas, widgets, accesibilidad y estados de carga y error.
- 2 – 13 nov · Ambos: sesión de retroalimentación con Process Coaches en un entorno controlado. Se reprogramó desde la ventana del 5 – 16 de octubre.
- 9 – 13 nov · Ambos: implementar los ajustes que salgan del feedback (bugs y UI).
- 9 – 13 nov · JFH: respaldo automático entre modelos LLM cuando uno falla.
- Resultado esperado: prototipo con la UI final, la arquitectura MCP y varios conectores funcionando (Outlook, Microsoft 365 y datos de planta).

Fase 3 — Limpieza y MVP (16 de noviembre – 4 de diciembre)

- 16 – 24 nov · Ambos: pruebas y validación. Se amplía el set de evaluación a 30 – 50 casos reales de planta.
- 18 – 27 nov · JFH: estabilización y hardening:
- Cuenta de servicio dedicada para memory-extractor.
- Control de roles (RBAC) en modo estricto.
- Revisión de secretos y logs.
- 16 nov – 4 dic · PMC: manual de usuario en español con capturas y guía de operación.
- 23 – 27 nov · Ambos: limpieza de código obsoleto (componentes legacy, workflows plantilla y scripts temporales).
- 30 nov – 4 dic · Ambos: MVP de HERBIEE: congelar la versión, hacer la demo final y el traspaso.
- Resultado esperado: MVP de HERBIEE.
- 5.3 Actividades realizadas que no estaban contempladas
- Widgets personalizados y vistas de dashboard. El supervisor crea gráficas describiéndolas en lenguaje natural y arma su propia vista.
- Reportes enriquecidos del agente. Incluyen tablas, gráficas y métricas, y se exportan a PNG, CSV, DOCX y PDF.
- Arnés de evaluación del agente. Mide de forma automática la calidad de las respuestas.
- Turnos y rotación de tripulaciones. El agente entiende en qué turno y con qué tripulación ocurrió cada evento.
- Procedimiento guiado de fallas de torque. El agente lo sigue paso a paso.
- Migración al estándar de APIs de Ford.
- Roles de acceso administrados en base de datos. Son tres: Admin, Supervisor y Process Coach.
- Pipeline CI/CD. Cloud Build se encarga de las pruebas y las imágenes, y Tekton de la infraestructura con Terraform.

Selector de modelo LLM para el Admin. También se adaptó el cliente del agente a los cambios de modelos de FordLLM.

- 5.5 Costo estimado de las actividades realizadas

Como el equipo (JFH y PMC) no recibe pago, el costo de mano de obra es $0. Solo se cuenta la infraestructura en la nube; los días-persona son una referencia de esfuerzo, no un gasto.

El costo de el uso de infraestructura esta estimado para cuando se use en producción, actualmente el costo mensual total es menos de 40 USD.

Supuestos: precios de GCP en us-central1, con recursos de tamaño mínimo para desarrollo, y tipo de cambio de $18.5 MXN por USD [validar con la facturación real].

- Introducción (análisis, investigación de stack, planeación de arquitectura, prototipo UI). Esfuerzo: 16 días-persona. Costo: $0.
- Sombra con Process Coaches. Esfuerzo: 2 días-persona. Costo: $0.
- Memoria persistente entre sesiones. Esfuerzo: 6 días-persona. Usa Memorystore Redis Básico, unos USD 25 al mes. Costo del periodo: unos USD 50 (unos $900 MXN).
- Memoria a nivel usuario. Esfuerzo: 9 días-persona. Usa Cloud SQL con pgvector, Pub/Sub y la Cloud Function memory-extractor, unos USD 40 al mes. Costo del periodo: unos USD 80 (unos $1,500 MXN).
- Memoria a nivel planta. Esfuerzo: 11 días-persona. Reutiliza la misma infraestructura. Costo incremental: $0.
- Dashboard de KPIs, widgets y vistas. Esfuerzo: 8 días-persona. Usa consultas a BigQuery, unos USD 30 al mes. Costo del periodo: unos USD 60 (unos $1,100 MXN).
- Sistema modular MCP y conector Microsoft 365. Esfuerzo: 10 días-persona. El conector lo provee Ford. Costo incremental: $0.
- Diseño de UI (avance). Esfuerzo: 8 días-persona. El frontend corre en Cloud Run y escala a cero cuando no hay uso, unos USD 5 al mes. Costo del periodo: unos USD 10 (unos $200 MXN).
- Backend y base de datos de chat. Usan Cloud Run y Cloud SQL, unos USD 35 al mes. Costo del periodo: unos USD 70 (unos $1,300 MXN).
- CI/CD (Cloud Build y Tekton). Esfuerzo: 3 días-persona. Tekton lo provee Ford, unos USD 5 al mes. Costo del periodo: unos USD 10 (unos $200 MXN).

- Otras actividades no contempladas (evaluación, estándar de API, turnos y tripulaciones, roles, torque, selector de modelo, documentación). Esfuerzo: 19 días-persona. Costo incremental: $0.
- Modelos FordLLM. Los provee Ford internamente. Costo: [validar si existe un cargo interno].

Total estimado del periodo:

- Mano de obra: $0 (94 días-persona, unas 750 horas, aportadas sin pago).

Infraestructura: unos USD 280 (unos $5,200 MXN), es decir, unos USD 140 al mes (unos $2,600 MXN al mes).

- 5.6 Ahorro estimado por el proyecto

Supuestos [ajustar con datos de planta]:

24 supervisores (8 líneas × 3 turnos).

15 minutos ahorrados por persona al día.

240 días laborales al año.

Costo por hora de un supervisor: $200 MXN.

Ahorro en tiempo de supervisión:

- Viene de consultar KPIs, preparar reportes y gráficas, y priorizar el correo.
- 24 supervisores × 0.25 h × 240 días = 1,440 horas al año.
- 1,440 h × $200 MXN = $288,000 MXN al año (unos $24,000 MXN al mes).

Ahorro en costo de desarrollo para Ford: el desarrollo, unas 750 horas, no tuvo costo para la empresa. Con una tarifa de referencia de $350 MXN por hora [ajustar], equivale a unos $262,500 MXN. Este es un ahorro único, no mensual.

Ahorro en conectores futuros:

- Con el gateway MCP, una fuente de datos nueva se agrega con configuración, sin desarrollo ni redespliegue.
- Usar el conector oficial de Microsoft 365 de Ford evitó construir una integración propia.

Recuperación de la inversión:

- El costo de operación es de unos $2,600 MXN al mes, así que la inversión se recupera desde el primer mes.
- El ahorro neto es de unos $21,400 MXN al mes (unos $256,800 MXN al año).

Beneficios no monetizados:

- Respuesta más rápida a problemas de calidad (FRC) y de paros (JPH).
- Conocimiento de planta conservado y curado.

Evaluaciones PJO mejor enfocadas.

Conclusiones

Jorge Antonio Flores Hernandez:

Trabajé principalmente en el desarrollo del backend, en la implementación de los diferentes niveles de memoria del agente, en la integración de KPIs y en la arquitectura modular de conectores MCP. Estas actividades me enseñaron mucho sobre integrar servicios, manejar bases de datos y crear sistemas que crezcan sin problemas. También enfrenté retos con la infraestructura y los procesos internos de Ford, lo que mejoró mis habilidades para resolver problemas y trabajar en equipo. En general, esta experiencia fue muy valiosa, pues pude usar lo aprendido en mi carrera en un proyecto real y ayudar a crear una herramienta que facilita el trabajo de los supervisores y mejora las decisiones en la empresa.

Pablo Ernesto Moreno Cruz:
Durante esta etapa de nuestro proyecto pasamos de tener las bases a contar con una plataforma que ya se puede utilizar, tiene memoria, KPIs en vivo y un agente integrado. Entre algunas de mis contribuciones se encuentran más que nada cosas de front, entre ellas el dashboard de KPIs: unifique el encabezado y acople el chat del asistente a la derecha, agregue el drill down interactivo con deltas de sesión, alertas de objetivos y el conteo de incidentes en las tarjetas. También añadi búsqueda, ordenamiento y exportación a CSV de los registros cargados. Del lado del chat implemente el historial de conversaciones con búsqueda y resaltado de coincidencias, el modo pantalla completa, la opción de reescribir la última pregunta y volver a ejecutar al agente, y la recuperación segura por turno con tareas persistentes del asistente. En los widgets agregue la vista expandida temporal, el acceso a los registros relacionados desde las categorías de una gráfica guardada, la creación guiada con controles y la sincronización de vistas y widgets entre ventanas. Otra parte de mis contribuciones fue la localización: el agente, las explicaciones y recomendaciones de PJO y las propuestas de memoria ahora responden en el idioma que se tenga seleccionado (español o inglés).
También trabajé en mejorar la accesibilidad, la navegación con teclado, diseño responsivo y las animaciones de interacción. Además de quitar componentes y dependencias que ya no tenían uso y corregi los hallazgos de seguridad del análisis estático en las pruebas. Esta etapa me enseño que una interfaz que se siente bien se logra con muchos ajustes pequeños, y que depender de permisos, certificados y del pipeline de despliegue de Ford nos obliga a planear con más margen.

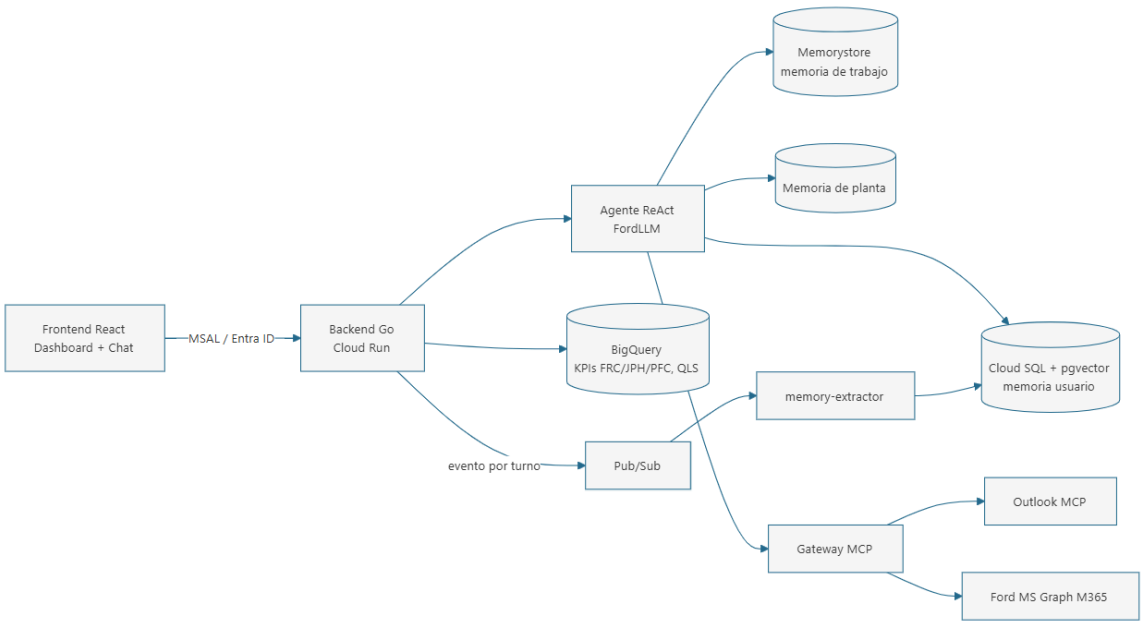
Bibliografía

Model Context Protocol. (2026, September 13). *What is the Model Context Protocol (MCP)?* https://modelcontextprotocol.io/docs/2026-07-28/getting-started/intro

Izgorodin, E. (2026, June 10). Federated MCP: How MCP Federation works in 2026. *Mnemoverse Documentation*. https://mnemoverse.com/docs/research/mcp/federated/architecture

Anexos

1. **Arquitectura Herbiee:**



2. Plan de Trabajo:

